

探討 GenAI 人機協作評量之信度與差異分析

張敦程

國立臺中教育大學 管理學院

dcchang@mail.ntcu.edu.tw

施育廷

國立臺中教育大學 教育資訊與測驗統計研究所

cms112103@gm.ntcu.edu.tw

摘要

在教育評量領域中，評分的公平性與客觀性至關重要。隨著生成式人工智慧技術成熟，其在學習評量上的應用潛力備受關注，但其評分標準與人類教師的差異仍需實證檢驗。本研究以台中市某大學一年級非資訊背景學生為研究對象，探討其於「資料科學與問題解決」課程中導入 AI 評分回饋系統的成效。研究分為兩階段進行：首先，由兩位具備不同專業背景的人類教師（老師 A 與老師 B）針對 100 份學生個人作業進行獨立評分，以檢驗並確立人類評分標準的信度；其次，針對學生分組進行的 20 組「議題分析報告」，導入團隊自主設計的 AI 評分回饋系統，藉此比較兩位教師與 AI 給分的差異。資料分析採用 SPSS 軟體進行成對樣本 t 檢定、皮爾森積差相關與組內相關係數（ICC）分析。

針對個人作業的初步分析顯示，兩位不同背景的教師具備極高的評分信度（ $r=.83$ ， $ICC=.82$ ， $p<.001$ ），顯示雙方對作業優劣具備高度共識。然而，成對樣本 t 檢定指出兩者在評分標準上存在顯著差異， $t(99)=5.25$ ， $p<.001$ ；老師 B 的平均分數（ $M=87.60$ ， $SD=10.66$ ）顯著高於老師 A（ $M=84.81$ ， $SD=10.94$ ），呈現系統性的給分尺度差異。其評分結果散佈圖如圖 1 所示。




圖 1 老師 A 與老師 B 評分結果散佈圖

在針對 20 組議題分析報告的人機協作階段（如表 1 所示），AI 評分與兩位人類教師皆呈現高度正相關（ r 分別為 .81 與 .80），證明 AI 能有效反映各組報告的品質差異。但在給分寬嚴度上，AI 的給分標準最為嚴格，其平均分數（ $M=86.70$ ）皆低於同批報告中的老師 A（ $M=87.80$ ）與老師 B（ $M=91.25$ ）。本研究亦將老師 A、老師 B 與 AI 進行評分視覺化，呈現每一組學生在三種評分下的得分情形。

表 1 人機協作評分之描述性統計與相關分析 ($N = 20$)

老師	M	SD	最小值	最大值	與老師 A 相關 (r)	與老師 B 相關 (r)
老師 A	87.80	6.85	70	99	-	.74
老師 B	91.25	4.89	73	99	.74	-
AI 評分	86.70	5.28	70	96	.81	.80

註：所有相關係數皆達統計顯著水準。




圖 2 評分趨勢圖

綜合上述結果，本研究證實人類教師與 AI 對表現優劣的排序具有高度一致性。本研究設計 AI 評分回饋系統的初衷涵蓋雙重面向：對學生而言，可在學習過程中利用此系統即時了解自身不足之處並進行修正；對教師而言，此自動化評分機制能有效降低大班級與多班級授課的教學負擔。然而，考量到人機之間仍存在不可忽視的給分寬嚴差異，建議在實務應用上，導入系統前必須針對 AI 模型進行分數校準（Calibration），以對齊人類教師的給分水平；同時，教學單位亦應建立定期抽檢機制，確保整體自動化評量的公平性與穩定性。

關鍵字：學習評量、生成式人工智慧、評分者間信度、人機協作、自動化評分